

Top1–Top2 Olasılık Farkı ile Cevap Doğruluğu Tahmini

Betül Arslan

Hesaplamalı Anlambilim Dersi – Final Projesi

betullarslan@gmail.com

Özet—Bu çalışmada, Cosmos-T1 (ytu-ce-cosmos/Turkish-Gemma-9b-T1) modelinin Türkçe matematik sorularına verdiği cevapların doğruluğu, üretim sürecindeki top1–top2 token olasılık farklarından çıkarılan istatistiksel özellikler kullanılarak tahmin edilmektedir. 1776 soru üretilmiş; her cevap için 18 özellik hesaplanmış ve üç makine öğrenmesi sınıflandırıcısı (Logistic Regression, Random Forest, Gradient Boosting) test edilmiştir. Random Forest $n = 100$ test setinde $F1=0.7429$, Gradient Boosting ise $AUC=0.7936$ başarımı sağlamıştır. Sonuçlar, modelin kendi üretim sürecinden elde edilebilen “iç sinyal” tabanlı bir cevap kalite göstergesinin mümkün olduğunu ortaya koymaktadır.

Index Terms—büyük dil modelleri, token olasılığı, cevap doğruluğu tahmini, makine öğrenmesi, Türkçe NLP, Cosmos-T1

I. GİRİŞ VE HIPOTEZ

Büyük dil modellerinin (LLM) her üretim adımında bir token dağılımı hesapladığı bilinmektedir. Bu dağılımın en yüksek iki olasılığı arasındaki fark (*top1–top2 diff*), modelin o adımda ne kadar “emin” olduğunu yansıtır.

Hipotez: Doğru cevap üreten model, doğru yolda ilerlerken genel olarak daha emin (yüksek fark) tokenlar üretir; yanlış cevaplarda bu güven daha düşük ya da daha değişken olur. Dolayısıyla üretilen fark dizisinden çıkarılan istatistiksel özellikler, cevabın doğru/yanlış olduğunu tahmin etmek için kullanılabilir.

t adımıdaki fark şu şekilde tanımlanır:

$$\delta_t = P(\text{top}_1, t) - P(\text{top}_2, t), \quad t = 1, 2, \dots, T \quad (1)$$

Bir cevap için T tokenlık $\{\delta_t\}_{t=1}^T$ dizisinden 18 istatistiksel özellik elde edilmekte ve bu özellikler sınıflandırıcıya verilmektedir.

II. MODEL VE VERİ KÜMESİ

A. Cosmos-T1

ytu-ce-cosmos/Turkish-Gemma-9b-T1 (Cosmos-T1), Gemma-2 9B mimarisi üzerine Türkçe matematik soruları için ince ayar yapılmış bir modeldir [1]. Modelin kritik özelliği, cevap üretmeden önce <think> bloğu içinde ayrıntılı bir düşünce zinciri (chain-of-thought, CoT) oluşturmasıdır.

B. gsm8k_tr Veri Kümesi

ytu-ce-cosmos/gsm8k_tr [2] veri kümesinin eğitim bölümü 8 792 Türkçe ilkökul matematik sorusu içermektedir. Boş ve hatalı örnekler temizlenerek **8 768 temiz örnek** elde edilmiştir [3].

Tablo I
ÜRETİM PARAMETRELERİ

Parametre	Değer
MAX_NEW_TOKENS	128
BATCH_SIZE	8
N_RUN	1776
Donanım	L4 22.5 GB, bfloat16
Ortalama süre	≈18.5 soru/dk

III. YÖNTEM

A. Top1–Top2 Fark Dizisinin Çıkarılması

generate() fonksiyonu output_scores=True ve return_dict_in_generate=True bayrakları ile çalıştırılarak her token adımının logit vektörü alınmıştır:

```
def top_diffs_from_scores(scores):
    diffs = []
    for step_logits in scores:
        probs = torch.softmax(
            step_logits[0].float(), dim=-1)
        top2 = torch.topk(probs, k=2)
        diffs.append(
            (top2.values[0]-top2.values[1]).item())
    return diffs
```

B. Özellik Çıkarma

Her cevaptan elde edilen $\{\delta_t\}$ dizisinden aşağıdaki 18 istatistiksel özellik hesaplanmıştır: mean, median, std, min, max, q25, q75, iqr, skewness, kurtosis, prop_high, prop_low, prop_medium, mean_first10, mean_last10, trend, n_tokens, min_region_mean.

C. Üretim Parametreleri

Tablo I’de üretim konfigürasyonu özetlenmektedir.

IV. ÜRETİM SÜRECİ VE GÖZLEMLER

1776 soru üzerinde üretim yapılmış; model doğruluğu %31.0 olarak gözlemlenmiştir (Tablo II).

Düşük doğruluk oranı, modelin <think> etiketiyle uzun CoT üretmesi ve MAX_NEW_TOKENS=128 kısıtı nedeniyle nihai <sayı> yanıtına ulaşamamasından kaynaklanmaktadır.

Dengeli bir veri kümesi oluşturmak için her sınıftan 500 eğitim ve 50 test örneği seçilmiştir (Tablo III).

Tablo II
ÜRETİM SONUÇLARI

	Sayı	Oran
Toplam soru	1776	%100
Model doğru	551	%31.0
Model yanlış	1225	%69.0

Tablo III
DENGELİ VERİ KÜMESİ

Küme	Doğru	Yanlış	Toplam
Eğitim	500	500	1000
Test	50	50	100
Toplam	550	550	1100

V. MAKİNE ÖĞRENMESİ MODELLERİ

A. Model Konfigürasyonları

Üç sınıflandırıcı sklearn [4] Pipeline içinde SimpleImputer(strategy="mean") ile birlikte kullanılmıştır:

- **Logistic Regression** — C=1.0, max_iter=1000
- **Random Forest** — n_estimators=200, max_depth=6
- **Gradient Boosting** — n_estimators=200, lr=0.05

B. Sonuçlar

VI. SONUÇLARIN ANALİZİ

A. Confusion Matrix

Şekil 1'de görüldüğü üzere Random Forest en düşük yanlış pozitif (FP=16) ile yanlış sınıfları en iyi ayırt ederken, Gradient Boosting FP=18 ile ikinci, Logistic Regression ise FP=19 ile üçüncü sıradadır. Gradient Boosting en yüksek FN (FN=14) değeriyle doğru cevapları kaçırma açısından en zayıf kalmıştır.

B. ROC Eğrisi

Şekil 2, tüm modellerin AUC>0.7 olduğunu göstermektedir; bu durum top1-top2 fark sinyalinin rastgele tahminden anlamlı biçimde daha iyi olduğunu kanıtlamaktadır. GB en yüksek AUC (0.794) ile eşik bağımsız ayırt etmede öne çıkmaktadır.

C. Feature Importance

mean_first10'un birinci sırada yer alması, 128-token kısa üretimde başlangıç güven profilinin belirleyici sinyal taşıdığını göstermektedir.

D. Top1-Top2 Fark Dağılımı

Şekil 4, doğru cevaplar için ortalama farkın yanlış cevaplara kıyasla hafifçe daha yüksek olduğunu göstermektedir; ancak iki dağılım örtüşmektedir. Bu, tek eşik ile mükemmel ayırım yapılamayacağını, ancak birleşik özelliklerin topluluk yöntemleriyle (RF F1=0.7429, GB AUC=0.7936) anlamlı tahmin yapılabilirliği sağladığını ortaya koymaktadır.

Tablo IV
ML MODEL KARŞILAŞTIRMASI ($n_{\text{TRAIN}} = 1000$, $n_{\text{TEST}} = 100$)

Model	Acc	Prec	Rec	F1	AUC
LR	0.690	0.667	0.760	0.710	0.708
RF	0.730	0.709	0.780	0.743	0.782
GB	0.680	0.667	0.720	0.692	0.794

Tablo V
EN ÖNEMLİ 5 ÖZELLİK (GB, $n_{\text{TRAIN}} = 1000$)

Sıra	Özellik	Önem
1	mean_first10	0.187
2	q75	0.100
3	mean_last10	0.085
4	min_region_mean	0.078
5	trend	0.076

VII. TARTIŞMA

A. Model Seçimi: F1 ve AUC Açısından

Özellikler ile etiket arasındaki ilişki doğrusal değildir. Logistic Regression bu nedenle daha düşük başarımla sergilemektedir (Acc=0.69, F1=0.710). Random Forest, özellik uzayındaki karmaşık etkileşimleri doğrusal olmayan karar sınırlarıyla yakalayabilmekte ve F1 metriğinde lider (0.743) olmaktadır. Gradient Boosting ise AUC metriğinde (0.794) öne çıkmaktadır.

B. Sınırlılıklar


- 1) **Test kümesi büyüklüğü:** 100 örneklik test kümesi istatistiksel güç için sınırlıdır; en az 200 örnek önerilmektedir.
- 2) **MAX_NEW_TOKENS kısıtı:** <think> tabanlı model için 128 token yetersizdir; idealinde en az 2048 token kullanılmalıdır.
- 3) **Sınıf dengesizliği:** Gerçek dağılımda %69.0 yanlış mevcuttur; gerçek dünya uygulaması bu dengesizliği hesaba katmalıdır.

VIII. SONUÇ


Bu çalışma, Cosmos-T1 modelinin üretim sürecinde elde edilen top1-top2 olasılık farklarından istatistiksel özellikler çıkararak cevap doğruluğunun makine öğrenmesi ile tahmin edilebildiğini göstermiştir.

- 1776 soruluk üretimden 18 özellikli vektörler oluşturulmuş, dengeli eğitim ($n = 1000$) ve test ($n = 100$) kümeleri elde edilmiştir.
- Random Forest **Acc=0.73**, **F1=0.7429** ile en yüksek F1, Gradient Boosting **AUC=0.7936** ile en yüksek AUC sağlamıştır.
- mean_first10 her iki modelde açık ara birinci özellik olmuştur (GB önem: 0.187).
- Tüm modeller AUC>0.7 elde etmiştir; sinyal anlamlı ve tutarlıdır.

Final Confusion Matrix Karşılaştırması



Şekil 1. Üç modele ait confusion matrix'ler (100 test örneği). LR: 31TN/19FP/12FN/38TP. RF: 34TN/16FP/11FN/39TP. GB: 32TN/18FP/14FN/36TP.




Şekil 2. Final ROC eğrileri: LR (AUC=0.708), RF (AUC=0.782), GB (AUC=0.7936).


Sonuç olarak, top1–top2 farkı ek dış bilgi gerektirmeksizin modelin kendi üretim sürecinden elde edilebilen bir cevap kalite göstergesi olarak umut vericidir.

KAYNAKLAR

- [1] YTU CE Cosmos, “Turkish-Gemma-9b-T1,” Hugging Face, 2024. [Online]. Available: <https://huggingface.co/ytu-ce-cosmos/Turkish-Gemma-9b-T1>
- [2] YTU CE Cosmos, “gsm8k_tr,” Hugging Face, 2024. [Online]. Available: https://huggingface.co/datasets/ytu-ce-cosmos/gsm8k_tr
- [3] K. Cobbe et al., “Training Verifiers to Solve Math Word Problems,” *arXiv:2110.14168*, 2021.
- [4] F. Pedregosa et al., “Scikit-learn: Machine Learning in Python,” *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.



Şekil 3. RF (sol) ve GB (sağ) için özellik önem sıralaması.



Şekil 4. Doğru/yanlış cevaplarda ortalama fark dağılımı ve örnek token bazlı fark grafikleri.